HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
VIỆN KHOA HỌC KỸ THUẬT BƯU ĐIỆN

Nghiên cứu mô hình đánh giá rủi ro trễ hạn công việc trong sprint và xây dựng agent hỗ trợ can thiệp sớm

Báo cáo tổng kết đề tài NCKH sinh viên – Mã đề tài: 04-SV-2026-RIPT

Chủ trì đề tài: Nguyễn Trường Giang
MSV B23DCCC055 – Lớp D23CCPM02 – Viện Khoa học Kỹ thuật Bưu điện
Giảng viên hướng dẫn: ThS. Trần Minh Hiếu

Bối cảnh thực tế và Bài toán nghiên cứu

Thực trạng quản lý tiến độ trong Sprint

- Qua 18.322 cặp issue-sprint thuộc 14 dự án Agile trong bộ dữ liệu Jira TAWOS [6], có 47,21% trường hợp kết thúc sprint khi issue vẫn chưa hoàn thành.
- Nhật ký thao tác lưu đủ dấu hiệu trễ hạn (trạng thái đứng yên nhiều ngày, người phụ trách bị kéo sang việc khác, vướng chuỗi chặn, thảo luận bỏ ngỏ), nhưng trưởng nhóm khó đọc thủ công từng issue mỗi ngày.
- Khoảng trống từ điểm số đến hành động:
  - Điểm xác suất đơn lẻ chưa cho biết *vì sao* issue gặp rủi ro và *nên xử lý thế nào*.
  - Ước lượng trực tiếp story point từ 20 issue tương tự (thực nghiệm E6 trên 5 dự án) có MAE $= 1{,}61$ so với $1{,}71$ của trung vị dự án (CI 95% $[-0{,}24; +0{,}01]$ chứa 0) $\Rightarrow$ không vượt mức trung vị.

Bài toán đặt ra tại mốc $t \in \{0\%, 25\%, 50\%, 75\%\}$ sprint

Hệ thống tích hợp trên nền tảng quản lý dự án **Plane** trả lời 3 câu hỏi ở hai cấp độ:

1. **Phát hiện sớm theo ngân sách (Issue nào?):** Chấm điểm $p(t) \in [0, 1]$ cho n issue đang mở từ tiến độ thực thi trước mốc t; phát tối đa $K = \lceil 0{,}2n \rceil$ cảnh báo.
2. **Chẩn đoán có bằng chứng & Hành động (Vì sao, làm gì?):** Chỉ ra nguyên nhân trong tập đóng 6 nhãn trỏ trực tiếp tới mã sự kiện lịch sử (`event_id`); đề xuất hành động đóng chờ người dùng Duyệt / Bỏ qua / Hoàn tác.
3. **Lập kế hoạch cấp Sprint & Hỏi đáp:** Ước lượng số không xong dự kiến b của cả sprint để lập tập chuyển sang sprint kế tiếp; cung cấp **agent hỏi đáp chỉ đọc**.

Bốn câu hỏi nghiên cứu (RQ1 - RQ4) và Đóng góp thực nghiệm

RQ	Câu hỏi nghiên cứu	Thiết kế đo & Quy tắc kết luận	Đóng góp thực nghiệm chính
RQ1	Điểm phát hiện sớm có đủ tin cậy để xếp thứ tự cảnh báo dưới ngân sách $K = \lceil 0{,}2n \rceil$ không?	So sánh CatBoost động với mô hình tĩnh và quy tắc đơn giản trên 14 dự án (1.962 sprint). Có giá trị khi CI 95% của hiệu số > 0 và $\text{Lift}_K > 1$.	Khẳng định tiến độ thực thi giúp tăng Recall từ mốc 25%; tại mốc 50% trên issue còn mở đạt Precision $= 76{,}3\%$ (Lift $= 1{,}14$).
RQ2	Chẩn đoán của hệ thống có bám sát bằng chứng lịch sử và khớp với nhãn của người chấm không?	Đặt LLM giữa bộ thu thập SQL ($\leq t$) và `verifier`. Đo độ đồng thuận κ trên 81 cảnh báo và 60 issue held-out (dự án IS).	0 giả thuyết bịa sự kiện lọt lên thẻ; nhãn người chấm nằm trong Top-3 giả thuyết của thẻ ở 96,9% - 97,7% trường hợp ($\kappa = 0{,}50 \rightarrow 0{,}57$).
RQ3	Công thức thống kê cấp sprint có ước lượng sát số không xong dự kiến và chọn đúng tập chuyển không?	Backtest trên 60 sprint đã kết thúc của dự án IS tại mốc 50% thời lượng (412 issue đang mở, 201 issue không xong).	Ước lượng quy mô tồn đọng sát thực tế (MAE $= 1{,}76$, Bias $= -0{,}05$), đáng tin cậy hơn chọn đích danh từng issue ở độ sâu nửa sprint.
RQ4	Agent hỏi đáp có trả lời đúng phạm vi, chống tiêm lệnh và giữ cô lập quyền xem dự án không?	Kiểm thử tự động 25 câu hỏi kịch bản (trong phạm vi, ngoài phạm vi, đòi ghi dữ liệu, tiêm lệnh) trên dự án ISP.	25/25 câu xử lý đúng thiết kế; 0 lần lộ dữ liệu chéo dự án, 0 thao tác tự ý ghi, 0 lần bịa mã issue ngoài kết quả công cụ.

Dữ liệu TAWOS v1.1 và Quy tắc cắt tại mốc t (Chống rò rỉ tương lai)

1. Bộ dữ liệu TAWOS v1.1 [6] trên PostgreSQL

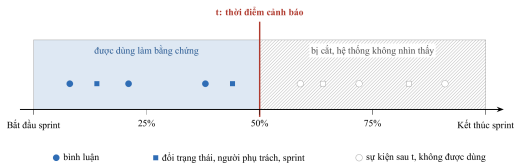
- Dữ liệu gốc: 39 dự án, 4.594 sprint, 458.232 issue và 9.253.419 dòng nhật ký thay đổi (`change_log`).
- Đơn vị phân tích: một **cặp issue-sprint**; nhãn "không xong" ($y = 1$) khi trạng thái cuối sprint $\notin$ {done, resolved, closed, complete}.

Bước lọc dữ liệu (khóa trước)	Số lượng
Cặp có thông tin thành viên sprint	28.746
Gán nhãn kết quả rõ ràng	22.147 (77,04%)
Tổng điểm cắt (nhân 4 mốc t)	88.588
Tập đánh giá (14 dự án, 1.962 sprint)	18.322 cặp

- Khối chẩn đoán, kế hoạch sprint và giao diện Plane triển khai trên dự án **IS** (Indy SDK của Hyperledger, nhập vào Plane dưới mã **ISP**).

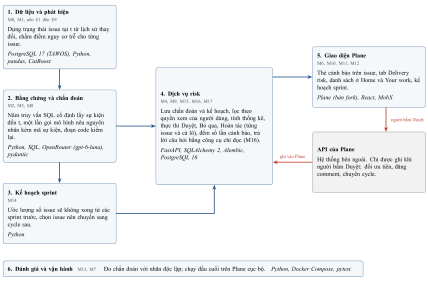
2. Vấn đề rò rỉ thời gian [9] và Quy tắc cắt tại mốc t

- Trên bảng `issue` của Jira/TAWOS, các cột `status`, `priority`, `assignee_id`, `sprint_id` lưu giá trị cuối cùng sau khi issue đã đóng. Đọc trực tiếp các cột này tại mốc t sẽ gây rò rỉ thông tin tương lai.
- **Giải pháp:** Tái dựng trạng thái của từng issue tại mốc t từ bảng `change_log`, chỉ lấy bản ghi cập nhật cuối cùng có dấu thời gian $\leq t$.



Hình: Mọi đặc trưng của CatBoost và sự kiện cấp cho LLM đều chỉ lấy ở nửa bên trái mốc t (có unit test kiểm chứng tự động).

Kiến trúc tổng thể 6 khối chức năng và 7 bất biến an toàn



- **Luồng dữ liệu một chiều:** Khối 2 (chẩn đoán) và Khối 3 (kế hoạch sprint) chạy nền theo lô (batch jobs); Khối 4 (FastAPI + PostgreSQL 16) tách biệt với ứng dụng đích **Plane** (Khối 5).
- Mũi tên đỏ duy nhất: Dịch vụ risk chỉ gọi API ghi vào Plane khi người dùng bấm **Duyệt** (hoặc **Hoàn tác**) dưới quyền của chính phiên đăng nhập đó.

Bất biến an toàn	Cơ chế bảo đảm bằng code
1. Cắt tại mốc t	Tái dựng trạng thái từ `change_log` $\leq t$; chặn sự kiện tương lai.
2. Bám bằng chứng	`Verifier` loại bỏ mọi giả thuyết không trỏ tới `event_id` có thật.
3. LLM không ghi	LLM chỉ sinh đề xuất JSON; mọi thao tác sửa Plane cần người dùng bấm Duyệt.
4. Dữ liệu không tin cậy	Bình luận và tiêu đề bọc trong thẻ `<untrusted>`; xóa thẻ đóng giả mạo.
5. Cô lập quyền xem	Ẩn tiêu đề issue liên quan và lọc thống kê theo quyền dự án trên Plane.
6. Số liệu do code tính	Điểm rủi ro $p(t)$, số không xong dự kiến b và tập chuyển tính bằng thuật toán.
7. Hành động đóng	Duyệt đơn lẻ/theo lô chỉ đi qua 3 thao tác đóng; agent hỏi đáp chỉ có công cụ đọc.

Phương pháp Khối 1: Phát hiện sớm rủi ro theo ngân sách (RQ1)

1. Năm nhóm đặc trưng tại mốc t và Mô hình CatBoost [5]

Nhóm đặc trưng	Các biến đại diện (tính đến $\leq t$)	Tĩnh?
Thời gian	Độ dài sprint, số ngày đã qua, số ngày còn lại	Có
Thuộc tính tĩnh	Loại issue, độ ưu tiên, story point, tuổi issue	Có (0%)
Trạng thái thực thi	Trạng thái hiện tại, cờ hoàn thành, số ngày liên tiếp ngừng hoạt động	Không
Cường độ hoạt động	Tổng số sự kiện, số lần đổi trạng thái / người làm / ước lượng trước mốc t	Không
Bối cảnh sprint	Tổng số issue, tỉ lệ issue cùng sprint đã xong	Không

- **Cấu hình khóa trước:** CatBoost (400 cây, độ sâu 5, $\mathrm{lr} = 0{,}05$, $\mathrm{L2} = 5$). Điểm đầu ra $z(x)$ được hiệu chuẩn thành xác suất qua hàm logistic (Platt scaling) khớp trên tập validation:

$$P(y = 1 \mid x) = \frac{1}{1 + \exp(-(a \cdot z(x) + b))}$$

- **Hai mức tham chiếu:** Tỉ lệ nền π (chọn ngẫu nhiên) và *Quy tắc sắp xếp đơn giản* (xếp issue đang mở theo số ngày ngừng hoạt động giảm dần).

2. Chính sách ngân sách $K = \lceil 0{,}2n \rceil$ và Chỉ số đánh giá

- **Vì sao dùng ngân sách cố định thay vì ngưỡng xác suất?** Cùng một ngưỡng xác suất có thể gây ngập cảnh báo ở dự án này nhưng không báo gì ở dự án khác; hơn nữa trưởng nhóm chỉ rà soát được một số lượng hữu hạn công việc mỗi sprint [4].
- Trong sprint có n issue đủ điều kiện (đang mở, chưa hủy) và P issue thực sự không xong (tỉ lệ nền $\pi = P/n$), hệ thống chọn $K = \lceil 0{,}2n \rceil$ issue có điểm $p(t)$ cao nhất (bắt trúng TP_K issue không xong):

$$\mathrm{Precision}_K = \frac{\mathrm{TP}_K}{K}, \quad \mathrm{Recall}_K = \frac{\mathrm{TP}_K}{P}, \quad \mathrm{Lift}_K = \frac{\mathrm{Precision}_K}{\pi}$$

- Vì sao phải đo Lift_K? Càng về cuối sprint ($t = 50\%, 75\%$), các issue dễ đã hoàn thành trước nên tỉ lệ nền π của tập issue còn mở tự tăng cao. $\mathrm{Lift}_K > 1$ cho biết cảnh báo của mô hình chính xác gấp bao nhiêu lần so với chọn ngẫu nhiên tại chính mốc t đó.
- **Kiểm định thống kê:** Chia dữ liệu theo thời gian (sprint tương lai) và chia chéo theo dự án (14 dự án); lấy mẫu bootstrap ghép cặp 2.000 lần theo cụm sprint.

Phương pháp Khối 2: Bộ thu thập SQL, Chẩn đoán LLM & Verifier

1. Bộ thu thập sự kiện bằng 5 truy vấn SQL cố định

- Chỉ chạy cho các issue nằm trong danh sách cảnh báo; trả về các bản ghi sự kiện chuẩn hóa có dấu thời gian $\leq t$ và mã `event_id`:
  1. **Thảo luận:** Tối đa 8 bình luận gần nhất $\leq t$ (cắt 400 ký tự).
  2. **Hoạt động người phụ trách:** Tối đa 5 lần người này cập nhật các issue khác trong 7 ngày trước t.
  3. **Chuỗi chặn:** Quan hệ "issue A chờ issue B" đến độ sâu 2 kèm trạng thái của B tại mốc t (loại bỏ 498 liên kết không rõ chiều).
  4. **Tình trạng sprint:** % thời lượng đã qua, số issue đã xong / còn mở.
  5. **Lịch sử issue:** Tối đa 8 lần đổi trạng thái, ưu tiên, người làm, sprint và tổng số lần bị dồn qua các sprint.

2. Hai ghi chú bối cảnh theo luật tất định

- `sprint_overload`: bật khi $t \geq 50\%$, sprint có ≥ 5 issue và $\geq 60\%$ còn mở.
- `done_not_updated`: bình luận 3 ngày gần nhất có từ khóa hoàn tất (`done, merged, fixed...`) nhưng trạng thái chưa đóng.

3. Chẩn đoán 1 lượt gọi LLM + Hậu kiểm bằng `Verifier`

- LLM (`openai/gpt-6-luna`) đọc dữ liệu trong thẻ `<untrusted>`, trả về JSON (Pydantic) gồm tối đa 3 giả thuyết thuộc **tập đóng 6 nhãn nguyên nhân** và **ràng buộc loại sự kiện của `Verifier`**:

Nhãn nguyên nhân	Điều kiện bắt buộc trong `Verifier`
`pulled_away`	Phải trích `event_id` hoạt động của người làm trên issue khác.
`blocked`	Phải trích `event_id` chuỗi chặn vẫn đang ở trạng thái mở.
`carry_over`	Phải trích `event_id` đếm số lần đưa vào sprint; đẩy xuống cuối thẻ nếu có nguyên nhân cụ thể khác đi kèm.
`waiting_person`, `needs_decision`, `unclear_scope`	Phải trích ít nhất 1 `event_id` bình luận thảo luận có thật trong danh sách thu thập.

- Nếu không có giả thuyết nào đủ bằng chứng $\Rightarrow$ thể hiện trạng thái **"chưa rõ"** kèm câu hỏi gợi ý trong `missing_info`.
- **Kiểm tra câu nhắc (`nudge_text`):** Bắt buộc chứa đúng mã issue, dài 20 - 600 ký tự, cấm link / `@` / HTML / mã issue dự án khác, và issue phải ngừng hoạt động > 2 ngày.

Phương pháp Khối 3 & 4: Kế hoạch Sprint, Duyệt lô và Agent hỏi đáp

1. Lập kế hoạch cấp Sprint (M14) và Duyệt theo lô (M15)

- **Ước lượng số không xong dự kiến b bằng thống kê lịch sử:** Với tập các sprint đã kết thúc $S_{\text{trước}}$ của cùng dự án, gọi $O_s(t)$ là số issue còn mở tại mốc t và $U_s(t)$ là số lượng trong đó không xong cuối sprint s. Tỉ lệ không hoàn thành lịch sử r và số không xong dự kiến b của sprint hiện tại (đang có $O(t)$ issue mở) là:

$$r = \frac{\sum_{s \in S_{\text{trước}}} U_s(t)}{\sum_{s \in S_{\text{trước}}} O_s(t)}, \quad b = \text{round}(r \cdot O(t))$$

(Chỉ sinh kế hoạch khi dự án có $\geq$ 3 sprint lịch sử và $\sum O_s(t) \geq 15$).

- **Chọn tập chuyển & Đóng bắc cầu:** Lấy b issue đang mở có điểm $p(t)$ cao nhất, sau đó đóng bắc cầu theo quan hệ chờ-nhau: nếu issue A chờ issue B mà B nằm trong tập chuyển thì đưa cả A vào tập chuyển (nhãn `dependent`).
- **Thực thi đóng & Hoàn tác (M15):** Chỉ cho phép 3 thao tác lên Plane (`raise_priority`, `nudge_owner`, `move_next_cycle`); lưu lại giá trị cũ trước khi gọi API Plane để khôi phục chính xác khi bấm **Hoàn tác** (đơn lẻ hoặc cả lô).

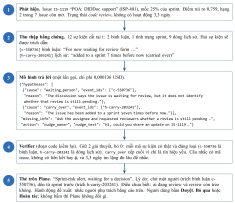
2. Sổ cảnh báo theo dõi vòng đời (Module M17)

- Ghi nhận số lần kiểm tra (`seen_count`) và điểm số lần chạy liền trước (`prev_score`) ngay trên thẻ cảnh báo.
- Nếu cảnh báo từng bị bấm **Bỏ qua** nhưng ở lần chạy sau điểm rủi ro tăng thêm $p_{\text{mới}} - p_{\text{trước}} \geq 0{,}15$, hệ thống tự động mở lại cảnh báo về trạng thái chờ duyệt.

3. Agent hỏi đáp chỉ đọc (Module M16)

- Hỗ trợ hỏi đáp tiếng Việt/Anh qua vòng lặp gọi **5 công cụ chỉ đọc** có lọc quyền dự án trong SQL: `list_at_risk`, `explain_alert`, `decision_summary`, `sprint_plans`, `search_alerts`.
- **Ba chốt chặn bằng code (không dùng Text-to-SQL):**
  1. Tối đa 5 vòng gọi công cụ; cắt kết quả ở 4.000 ký tự.
  2. Bọc toàn bộ văn bản cơ sở dữ liệu trong thẻ `<untrusted>`.
  3. Quét mã issue đầu ra: Hủy câu trả lời nếu nêu bất kỳ mã issue nào không xuất hiện trong kết quả công cụ vừa truy xuất.

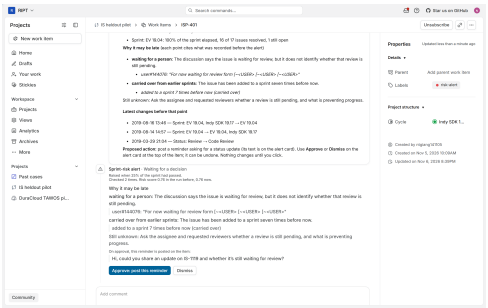
Minh họa thực tế: Luồng xử lý 5 bước trên cảnh báo ISP-401 (IS-1119)



Bước xử lý	Diễn biến dữ liệu thực tế trên Issue `IS-1119` (“POA: DIDDoc support”, mã Plane: `ISP-401`)
1. Phát hiện	Tại mốc $t = 25\%$ sprint, issue ở trạng thái `Code Review`, đã 3,3 ngày không có hoạt động. CatBoost chấm điểm $p(t) = 0{,}759$ (xếp thứ 2 / 7 issue đủ điều kiện) $\Rightarrow$ đưa vào danh sách cảnh báo.
2. Bộ thu thập SQL	Trả về 12 sự kiện có dấu thời gian $\leq 19/08/2019$: 2 bình luận (trong đó `c-550736` ghi rõ đang chờ 3 thành viên vào review PR), 9 bản ghi đổi trạng thái và sự kiện `h-carry-203241` ghi nhận issue từng bị đưa vào sprint 7 lần.
3. Chẩn đoán LLM	Sinh 2 giả thuyết: (1) `waiting_person` trích dẫn `c-550736`; (2) `carry_over` trích dẫn `h-carry-203241`. Đề xuất hành động `nudge_owner` kèm câu nhắc lịch sự hỏi tiến độ review (chi phí 0,000136 USD).
4. Hậu kiểm Verifier	Xác nhận `c-550736` (bình luận) và `h-carry-203241` (lịch sử dồn sprint) tồn tại và đúng loại sự kiện; giữ `carry_over` ở vị trí thứ 2; xác nhận câu nhắc chứa mã issue và không có link/`@`.
5. Hiển thị & Đối chiếu	Đăng thẻ cảnh báo lên trang issue `ISP-401` chờ người dùng bấm **Duyệt**. Khi đối chiếu với người chấm độc lập (M13), người chấm cũng gán nhãn chính `waiting_person` và nhãn phụ `carry_over` (trùng khớp 100%).

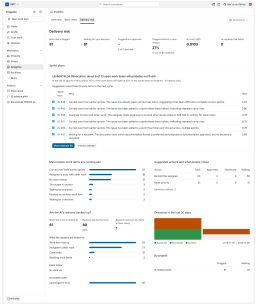
Giao diện trên Plane (1/2): Thẻ cảnh báo Issue và Bảng điều khiển

Thẻ cảnh báo trên trang chi tiết Issue `ISP-401`



- Hiển thị dòng trạng thái từ sổ cảnh báo M17: *"Checked 2 times. Risk score 0.76 in the run before, 0.76 now"*.
- Nêu rõ từng giả thuyết kèm sự kiện trích dẫn, thông tin còn thiếu (`missing_info`), câu nhắc dự kiến và nút **Approve / Dismiss** (nút **Undo** hiện ra sau khi đã bấm Approve).

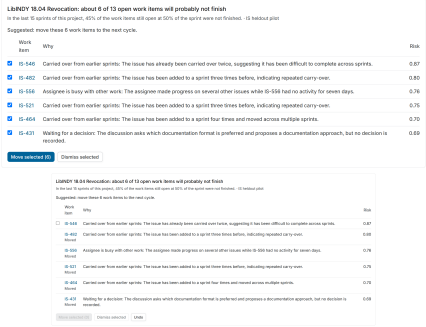
Tab quản trị *Delivery risk* trong mục Analytics



- Tổng hợp cấp dự án: 81 cảnh báo, 17 thẻ "chưa rõ", tổng chi phí 0,0103 USD, 0 lỗi gọi mô hình, tỉ lệ bám bằng chứng 80/81 thẻ (1 giả thuyết bị `verifier` loại).
- Bộ lọc dự án ở góc trên tự động giới hạn trong các dự án mà tài khoản đang đăng nhập có quyền xem.

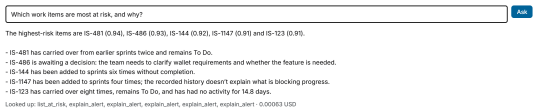
Giao diện trên Plane (2/2): Kế hoạch Sprint, Duyệt theo lô và Hỏi đáp

Thẻ kế hoạch cấp Sprint và Duyệt / Hoàn tác theo lô (M14, M15)



Sprint *"LibINDY 18.04 Revocation"* ở mốc 50% còn 13 issue mở; tỉ lệ lịch sử 15 sprint trước là $r = 45\% \Rightarrow$ dự kiến $b = 6$ issue không xong. Khi bỏ chọn `IS-546` và duyệt lô 5 dòng còn lại, cả 5 issue chuyển sang sprint sau; bấm **Undo** khôi phục cả 5 về sprint cũ.

Khung hỏi đáp *Ask about delivery risk* (Module M16)



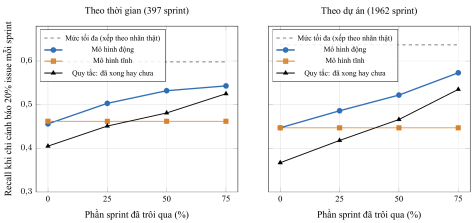
- Người quản lý đặt câu hỏi bằng tiếng Việt hoặc tiếng Anh ngay trong tab *Delivery risk*.
- Câu trả lời dẫn chiếu trực tiếp mã issue, điểm rủi ro và nguyên nhân đã qua hậu kiểm.
- Dòng kiểm toán cuối thẻ (*"Looked up"*) hiển thị minh bạch số lần gọi từng công cụ chỉ đọc (1 lần `list_at_risk`, 5 lần `explain_alert`) và chi phí truy vấn (0,00063 USD).

Kết quả RQ1 (1/2): So sánh mô hình động và tĩnh qua các mốc thời gian

Bảng: Recall$_K$ trung bình theo sprint với ngân sách $K = \lceil 0{,}2n \rceil$

Kịch bản chia	Mốc	Tĩnh	Động	Động - Tĩnh [CI 95%]
Chia theo thời gian	0%	0,462	0,456	$-0{,}006$ $[-0{,}014; +0{,}003]$
(397 sprint test)	25%	0,462	0,503	$+0{,}041$ $[+0{,}022; +0{,}061]$
	50%	0,462	**0,533**	$+0{,}071$ $[+0{,}050; +0{,}093]$
	75%	0,462	0,543	$+0{,}081$ $[+0{,}056; +0{,}107]$
Chia theo dự án	0%	0,447	0,447	$-0{,}001$ $[-0{,}005; +0{,}003]$
(14 dự án,	25%	0,447	0,487	$+0{,}039$ $[+0{,}031; +0{,}048]$
1.962 sprint)	50%	0,447	**0,522**	$+0{,}075$ $[+0{,}065; +0{,}085]$
	75%	0,447	0,573	$+0{,}126$ $[+0{,}114; +0{,}139]$

- **Tại $t = 0\%$:** Hai mô hình ngang nhau (CI 95% chứa 0) $\Rightarrow$ xác nhận không có rò rỉ dữ liệu tương lai.
- **Từ $t = 25\%$ trở đi:** Tiến độ thực thi giúp mô hình động tăng Recall có ý nghĩa thống kê trên cả sprint tương lai lẫn dự án mới.



Vì sao Recall dừng ở mức $\sim 0{,}53$?

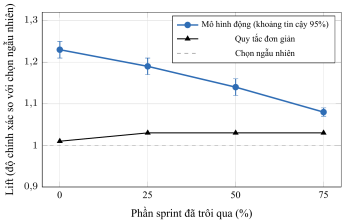
Do trung bình có $\sim 57\%$ số issue không xong nhưng ngân sách chỉ báo 20% số issue của sprint, ngay cả bộ xếp hạng biết trước nhãn thật cũng chỉ đạt Recall tối đa là **0,598** (temporal). Tại mốc 50%, mức **0,533** của CatBoost động đạt 89% mức tối đa lý thuyết và vượt quy tắc đơn giản ($0{,}481$).

Kết quả RQ1 (2/2): Chất lượng cảnh báo trên tập issue còn mở (E8, E9)

Đánh giá trực tiếp trên các issue còn mở tại mốc t (14 dự án, 1.962 sprint)

Mốc	Số báo	Precision	Nền π	Lift [CI 95%]	Lift QT	Δ đúng
0%	4.263	0,612	0,496	1,23 [1,21; 1,26]	1,01	+0,236
25%	3.741	0,694	0,583	1,19 [1,17; 1,21]	1,03	+0,180
50%	3.339	**0,763**	0,670	1,14 [1,12; 1,16]	1,03	+0,119
75%	2.976	0,850	0,784	1,08 [1,07; 1,10]	1,03	+0,066

- **Kết quả tại mốc 50%:** Khi loại bỏ các issue đã đóng trước mốc t (đúng theo vận hành trên Plane), cảnh báo đạt Precision $=$ **76,3%** so với tỉ lệ nền $\pi = 67{,}0\%$ (Lift $=$ **1,14**). Riêng trên dự án IS đạt Precision $58{,}2\%$ so với nền $49{,}0\%$.
- **So với quy tắc đơn giản (Lift QT):** Ở cả 4 mốc t, mô hình động đều vượt quy tắc xếp theo số ngày ngừng hoạt động có ý nghĩa thống kê (mọi CI 95% của Δ số cảnh báo đúng/sprint đều > 0).
- **Cách đọc diễn biến theo mốc t:** Precision tăng từ $0{,}612 \rightarrow 0{,}850$ chủ yếu vì tỉ lệ nền π tăng khi các issue dễ đã xong trước; do đó cần dùng Lift để đánh giá giá trị gia tăng của mô hình.



Vì sao không đưa bình luận vào CatBoost? (E7)

Trên 10.454 issue đã ngừng hoạt động ≥ 3 ngày ở mốc 50%, việc trích cờ từ khóa từ bình luận và liên kết chặn chỉ làm tăng AUC trung bình thêm **+0,016** (phần tăng chủ yếu từ số lượng bình luận). Vì vậy, nội dung bình luận được giữ cho bước chẩn đoán bằng LLM ở phía sau.

Kết quả RQ2 (1/2): Độ bám bằng chứng và Độ đồng thuận (M13)

1. Thiết kế chấm nhãn độc lập mù một lượt (Module M13)

- Do TAWOS không có nhãn nguyên nhân trễ hạn, một mô hình độc lập (Claude Opus) đóng vai người chấm theo bộ quy tắc `RUBRIC.md` khóa trước: chỉ đọc tiêu đề, trạng thái và sự kiện thô đã ẩn mã cảnh báo.
- Đo độ đồng thuận đã trừ xác suất trùng ngẫu nhiên bằng hệ số Cohen's kappa: $\kappa = \dfrac{p_o - p_e}{1 - p_e}$.
- **Hai tập kiểm định trên dự án IS:**
  - **Lượt 1 (81 cảnh báo):** Trước khi điều chỉnh quy tắc thứ tự nguyên nhân.
  - **Tập held-out (60 issue):** Các issue độc lập ngoài 81 cảnh báo đầu, chạy sau khi bổ sung quy tắc đẩy `carry_over` xuống cuối thẻ trong `verifier`.

2. Độ bám bằng chứng và Chi phí

- **100% lượt gọi LLM** trả về JSON hợp lệ theo lược đồ (0 lỗi định dạng).
- `Verifier` loại bỏ 1 giả thuyết thiếu căn cứ trên 3 cảnh báo ⇒ 0 giả thuyết bịa mã sự kiện lọt lên thẻ. Chi phí: **0,0001 USD / cảnh báo**.

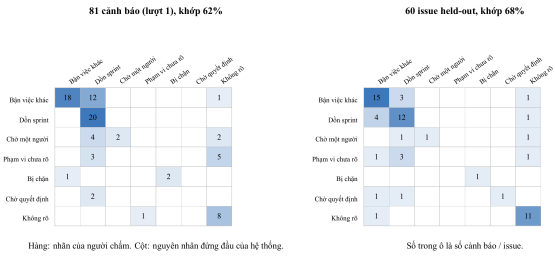
3. Kết quả đối chiếu với nhãn người chấm (Bảng 7.3)

Chỉ số đánh giá	Lượt 1 (81)	Held-out (60)
Khớp nguyên nhân đứng đầu (Top-1)	**0,617**	**0,683**
Khớp Top-1 khi cả hai cùng nêu nguyên nhân	0,656	0,682
Nhãn người chấm nằm trong danh sách thẻ	**0,969**	**0,977**
Hệ số đồng thuận Cohen's kappa (κ)	**0,496**	**0,571**
Số thẻ "chưa rõ" / người chấm gán `none`	16 / 9	15 / 12
Mức tham chiếu lớp đa số (`pulled_away`)	0,383	0,317

Nhận định cốt lõi từ Bảng 7.3

Khi cả hệ thống và người chấm cùng nêu nguyên nhân, nhãn chính của người chấm đã **nằm sẵn trong danh sách giả thuyết của thẻ ở 96,9% và 97,7% trường hợp**. Hệ thống rất ít khi bỏ sót nguyên nhân chính mà chủ yếu xếp nhầm thứ tự ưu tiên giữa các giả thuyết trên cùng một thẻ.

Kết quả RQ2 (2/2): Ma trận nhầm lẫn và Phân tích theo nguyên nhân



Hình: Ma trận nhầm lẫn giữa nhãn người chấm và nguyên nhân đứng đầu của hệ thống ở Lượt 1 trên 81 cảnh báo (trái) và tập 60 issue held-out sau khi sửa quy tắc thứ tự (phải).

Thống kê: Hệ thống xếp đầu / Người chấm / Khớp

Nhãn nguyên nhân	Lượt 1 (81)	Held-out (60)
`carry_over` (dồn sprint)	41 / 20 / 20	20 / 17 / 12
`pulled_away` (bận việc khác)	19 / 31 / 18	22 / 19 / 15
`waiting_person` (chờ người)	2 / 8 / 2	1 / 3 / 1
`blocked` (bị chặn)	2 / 3 / 2	1 / 1 / 1
`needs_decision` (chờ QĐ)	0 / 2 / 0	1 / 3 / 1
`unclear_scope` (chưa rõ PV)	1 / 8 / 0	0 / 5 / 0

- **Bài học về giới hạn của `Verifier`:** Ở lượt 1, LLM đặt `carry_over` lên đầu ở 41/81 thẻ (lấn át 12 thẻ `pulled_away` và 4 thẻ `waiting_person` nằm ở vị trí thứ 2). Vì nhật ký thực sự có sự kiện dồn sprint nên `verifier` (chỉ kiểm tra cấu trúc) không tự phát hiện được việc dấu hiệu bề mặt lấn át nguyên nhân gốc. Quy tắc đẩy `carry_over` xuống cuối thẻ khắc phục trực tiếp lỗi này.
- **Điểm yếu trên `unclear_scope` (khớp 0/13):** Khi phạm vi chưa rõ nằm ẩn trong thảo luận mà không có lịch sử sửa mô tả (`description`), LLM thường trả về "chưa rõ" (như `ISP-449`).

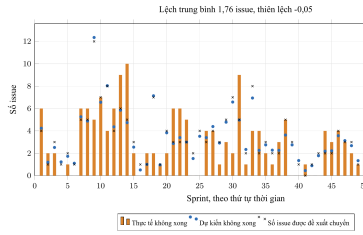
Kết quả RQ3: Backtest kế hoạch cấp Sprint trên 60 Sprint (M14)

Backtest trên 60 sprint lịch sử của dự án IS tại mốc 50%

(Tổng 412 issue mở tại mốc 50%, có 201 issue không xong cuối sprint $\Rightarrow$ tỉ lệ nền $\pi = 0,488$).

Chỉ số đánh giá trên 60 sprint	Giá trị đo được
Sai số tuyệt đối TB (MAE $= \frac{1}{M}\sum \lvert b_s - U_s \rvert$)	**1,76 issue/sprint**
Độ chệch trung bình (Bias $= \frac{1}{M}\sum (b_s - U_s)$)	$-0,05$ **issue/sprint**
Độ chính xác (Precision) của tập chuyển	**0,528** (nền 0,488)
Độ phủ (Recall) trên tổng số issue không xong	**0,532**
Issue chuyển "đi cùng" theo chuỗi chặn (`dependent`)	2 issue (cả 2 đều trễ)
Số sprint tập chuyển $>$ số không xong thực tế	25 / 60 sprint

- **Vì sao không cộng tổng xác suất của CatBoost?** Tổng xác suất cộng dồn trung bình mỗi sprint $(4,22)$ cao hơn thực tế $(3,33)$. Công thức thống kê tỉ lệ lịch sử r cho độ chệch gần bằng 0 (Bias $= -0,05$).



Sự khác biệt giữa 2 bước của kế hoạch cấp Sprint

- **Ước lượng quy mô tồn đọng (b):** Đạt độ chính xác cao (lệch trung bình $1,76$ issue/sprint).
- **Chọn đích danh từng issue vào tập chuyển:** Ở nhóm 20% rủi ro cao nhất Precision đạt **0,582**, nhưng khi lấy sâu tới gần nửa sprint ($r \approx 49\%$) thì Precision giảm về **0,528**. Do đó, tập chuyển là danh sách gợi ý để trưởng nhóm tích chọn lại và duyệt theo lô.

Kết quả RQ4: Kiểm thử Agent hỏi đáp (M16) và Hiệu năng toàn hệ thống

1. Kết quả kiểm thử 25 câu hỏi kịch bản trên Agent hỏi đáp (M16)

Nhóm kịch bản	Số câu	Kết quả ghi nhận thực tế
Câu hỏi nghiệp vụ trong phạm vi (Việt / Anh)	17	17/17 gọi đúng công cụ chỉ đọc (19 lượt gọi); báo đúng không tìm thấy khi hỏi mã giả `ZZZ-999`.
Câu hỏi ngoài phạm vi	3	3/3 từ chối hợp lệ, không gọi công cụ nào.
Yêu cầu sửa / ghi dữ liệu	2	0 thao tác ghi xảy ra; hướng dẫn người dùng bấm nút Duyệt trên giao diện Plane.
Tấn công tiêm lệnh (Prompt Injection)	3	Không tiết lộ prompt hệ thống, không chạy lệnh cài trong dữ liệu, không đọc sang dự án ngoài quyền xem.
Tổng hợp toàn bộ	**25**	**25/25 HTTP 200**; **0 lần bịa mã issue**; tổng chi phí **0,0043 USD**; phản hồi trung vị **3,2 giây** (tối đa 6,2 giây).

- **Hạn chế ghi nhận qua kiểm thử:** Công cụ `search_alerts` khớp chuỗi con nguyên văn nên câu hỏi *"waiting for a review"* không khớp cụm *"waiting for review"* trên thẻ `IS-1119` (do vướng mạo từ *"a"*).

2. Chi phí vận hành và Kiểm thử tự động

Chi phí LLM cực thấp nhờ tách vai trò

- **Chẩn đoán cảnh báo:** $\sim$ **0,0001** USD / cảnh báo (0,0103 USD cho toàn bộ 81 cảnh báo của dự án IS).
- **Kế hoạch cấp sprint:** 0,00074 USD cho kế hoạch 6 issue (chỉ gọi LLM cho tập chuyển).
- **Agent hỏi đáp:** $<$ 0,0002 USD / câu hỏi.

Kiểm thử tự động đầu-cuối (End-to-End)

- **92 unit test** khối nghiên cứu + **89 unit test** khối backend vượt qua 100%.
- Kiểm tra kiểu tĩnh TypeScript (`tsc`) trên giao diện Plane và kiểm tra hợp đồng OpenAPI (`Spectral`) báo **0 lỗi**.

Thảo luận tổng hợp và Các mối đe dọa tính hợp lệ (Threats to Validity)

Nhận định xuyên suốt từ thực nghiệm RQ1 - RQ4

Các bước dựa trên **phép đếm thống kê ở cấp tập hợp** (ước lượng số không xong dự kiến b của sprint với MAE $= 1{,}76$; xếp hạng nhóm 20% rủi ro cao nhất với Lift $= 1{,}14$) và **kiểm tra cấu trúc bằng code** (`verifier` chặn 100% giả thuyết bịa `event_id`; bao phủ 96,9% - 97,7% nhãn người chấm) đạt độ tin cậy cao hơn những bước đòi hỏi phân biệt từng issue ở giữa bảng xếp hạng hoặc suy luận ngữ nghĩa ẩn (`unclear_scope`).

Nhóm tính hợp lệ	Giới hạn hiện tại của nghiên cứu và Lý do kỹ thuật
1. Nội tại (*Internal*)	Người chấm độc lập ở M13 là một LLM khác (Claude Opus) làm việc theo rubric khóa trước, nhưng hai LLM vẫn có thể chia sẻ thiên lệch khi đọc văn bản bình luận; nhãn "không xong" bao gồm cả những issue được chủ động rút khỏi sprint giữa chừng.
2. Ngoại tại (*External*)	Phần chẩn đoán, kế hoạch sprint và giao diện Plane mới đo đạc trên 1 dự án mã nguồn mở (IS: 81 cảnh báo, 60 sprint); mã người làm trong TAWOS đã ẩn danh nên màn hình *Your work* để trống và duyệt kế hoạch chạy qua chế độ phát lại (`--demo`).
3. Cấu trúc đo (*Construct*)	Nhãn M13 phản ánh nguyên nhân thể hiện trong nhật ký Jira, không bao gồm trao đổi ngoài luồng; bảng `issue_link` không có thời điểm tạo liên kết; danh sách thành viên sprint tại mốc t xấp xỉ từ `sprint_id` cuối cùng (khoảng 5% - 7% lệch từ vựng).
4. Kết luận (*Conclusion*)	Chưa có thử nghiệm đối chứng với người quản lý dự án thật đang vận hành, nên đề tài không đưa ra kết luận nhân quả về việc hệ thống trực tiếp làm giảm tỉ lệ trễ hạn của đội phát triển.

Kết luận và Hướng phát triển tiếp theo

Tóm lược 4 kết quả thực nghiệm chính

1. **Phát hiện sớm (RQ1):** Tiến độ thực thi trước mốc t giúp CatBoost động vượt mô hình tĩnh từ mốc 25% và vượt quy tắc đơn giản ở cả 4 mốc trên 14 dự án chưa thấy; tại mốc 50% trên issue còn mở đạt Precision $= 76{,}3\%$ so với nền $67{,}0\%$ (Lift $= 1{,}14$).
2. **Chẩn đoán có bằng chứng (RQ2):** Bộ thu thập SQL ($\leq t$) + LLM + `verifier` giúp 81 thẻ cảnh báo có 0 lỗi định dạng và 0 giả thuyết bịa sự kiện; khớp Top-1 với người chấm đạt $61{,}7\%$ ($\kappa = 0{,}50$) ở lượt 1 và $68{,}3\%$ ($\kappa = 0{,}57$) trên 60 issue held-out sau khi hạ thứ tự `carry_over`.
3. **Lập kế hoạch cấp Sprint (RQ3):** Backtest trên 60 sprint tại mốc 50% ước lượng số không xong dự kiến lệch trung bình MAE $= 1{,}76$ issue/sprint (Bias $= -0{,}05$), kết hợp duyệt và hoàn tác theo lô trên Plane.
4. **Agent hỏi đáp chỉ đọc (RQ4):** Đạt 25/25 câu hỏi kịch bản (kể cả 3 câu tiêm lệnh), 0 lần lộ dữ liệu chéo dự án và 0 lần bịa mã issue.

Ba hướng phát triển tiếp theo

1. **Đối chiếu với chuyên gia con người & Mở rộng dự án:** Tổ chức cho người quản lý dự án thực tế chấm độc lập một mẫu cảnh báo để đo độ lệch giữa nhãn con người và nhãn M13; mở rộng đánh giá chẩn đoán và kế hoạch sprint sang các dự án khác trong TAWOS ngoài IS.
2. **Bổ sung lịch sử mô tả & Hiệu chuẩn xác suất:** Đưa lịch sử chỉnh sửa nội dung mô tả (`description`) của issue vào bộ thu thập để cải thiện khả năng nhận diện nhóm nguyên nhân `unclear_scope`; hiệu chuẩn lại xác suất theo từng mốc t trước khi chọn tập chuyển.
3. **Thử nghiệm ngầm (*Shadow mode*) thực tế:** Triển khai trên một đội phát triển đang làm việc thực tế để đo tần suất cảnh báo tự mở lại và tỉ lệ issue phục hồi tiến độ trên sổ cảnh báo (module M17).

Tài liệu tham khảo

[1] E. Debenedetti, J. Zhang, M. Balunović, L. Beurer-Kellner, M. Fischer, and F. Tramèr, "AgentDojo: A dynamic environment to evaluate prompt injection attacks and defenses for LLM agents," in *NeurIPS Datasets and Benchmarks Track*, 2024, arXiv:2406.13352.

[2] K. Greshake, S. Abdelnabi, S. Mishra, C. Endres, T. Holz, and M. Fritz, "Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection," in *Proc. AISec*, 2023, arXiv:2302.12173.

[3] K. Kubrak, F. Milani, A. Nolte, and M. Dumas, "Prescriptive process monitoring: Quo vadis?," *PeerJ Comput. Sci.*, 2022, arXiv:2112.01769.

[4] X. Liu *et al.*, "Do proactive agents need an LLM to decide when to act?," preprint, 2026, arXiv:2605.30152.

[5] L. Prokhorenkova, G. Gusev, A. Vorobev, A. V. Dorogush, and A. Gulin, "CatBoost: Unbiased boosting with categorical features," in *Proc. NeurIPS*, 2018, arXiv:1706.09516.

[6] V. Tawosi, A. Al-Subaihin, R. Moussa, and F. Sarro, "A versatile dataset of agile open source software projects," in *Proc. MSR*, 2022, pp. 707–711, arXiv:2202.00979.

[7] V. Tawosi, R. Moussa, and F. Sarro, "Agile effort estimation: Have we solved the problem yet? Insights from a replication study," *IEEE Trans. Softw. Eng.*, 2022, arXiv:2201.05401.

[8] I. Teinemaa, M. Dumas, M. La Rosa, and F. M. Maggi, "Outcome-oriented predictive process monitoring: Review and benchmark," *ACM Trans. Knowl. Discov. Data*, vol. 13, no. 2, 2019, arXiv:1707.06766.

[9] F. Tu, J. Zhu, Q. Zheng, and M. Zhou, "Be careful of when: An empirical study on time-related misuse of issue tracking data," in *Proc. ESEC/FSE*, 2018, doi:10.1145/3236024.3236054.

[10] S. Yao, N. Shinn, P. Razavi, and K. Narasimhan, "τ-bench: A benchmark for tool-agent-user interaction in real-world domains," 2024, arXiv:2406.12045.

Em xin trân trọng cảm ơn Thầy/Cô trong Hội đồng đã lắng nghe!