Nghiên cứu mô hình đánh giá rủi ro trễ hạn công việc trong sprint và xây dựng agent hỗ trợ can thiệp sớm

Báo cáo tiến độ – Mã đề tài: 04-SV-2026-RIPT

Chủ trì đề tài: Nguyễn Trường Giang

MSV B23DCCC055 – Lớp D23CCPM02

GVHD: ThS. Trần Minh Hiếu

Bối cảnh và bài toán

- Vấn đề: 47,21% cặp issue–sprint không hoàn thành đúng hạn; số cảnh báo mỗi sprint phải giới hạn.
- Bài toán: tại mốc $t \in \{0, 25, 50, 75\%\}$ sprint, ước lượng $P(\text{không hoàn thành} \mid \text{thông tin đến } t)$, dữ liệu tái dựng *as-of*.
- RQ1: lịch sử thực thi có giúp dự báo tốt hơn thông tin đầu sprint?
  RQ2: có giữ được trên sprint tương lai và dự án chưa thấy?
  RQ3: với số cảnh báo giới hạn, mô hình nào bắt được nhiều issue rủi ro hơn?
- Giả thuyết chính (đăng ký trước): tại mốc 50%, cùng ngân sách, mô hình *động* có recall cao hơn mô hình *tĩnh*.
- Hai phần: mô hình chọn *issue nào* cần chú ý; agent giải thích *vì sao*, kèm bằng chứng.

Dữ liệu TAWOS v1.1 và thiết kế đánh giá

	Gốc	Đánh giá
Dự án	39	14
Sprint	4.594	1.962
Issue / cặp	458.232	18.322

- Nhãn: trạng thái tại ngày kết thúc sprint không thuộc {Done, Resolved, Closed, Complete}.
- Kiểm tra chéo nhãn bằng SQL độc lập trên 765 cặp.

Temporal (sprint tương lai)
Train trên sprint cũ, test trên sprint mới hơn.

	Train	Validation	Test
Cặp	11.500	3.401	3.293

Vùng *purge* (128 cặp) tách train và test để tránh rò rỉ.

Cross-project (dự án chưa thấy)
Lần lượt giữ 1 trong 14 dự án làm test, train trên 13 dự án còn lại.

Đặc trưng và mô hình

Nhóm đặc trưng	Mô hình tĩnh?
Timing	có
Attributes	có (tại đầu sprint)
Execution state	không
Prefix activity	không
Cohort context	không

Chỉ dùng thông tin có trước hoặc đúng thời điểm mốc.

6 mô hình so sánh

1. Frequency (tỷ lệ lịch sử)
2. Quy tắc nghiệp vụ: Done → 0,01; còn lại clip$(0{,}5 + 0{,}02d + 0{,}1u)$
3. Logistic Regression tĩnh
4. CatBoost tĩnh
5. CatBoost động
6. CatBoost động, bỏ nhóm cohort

CatBoost[2]: 400 cây, depth 5, lr 0,05, L2 = 5; hiệu chuẩn sigmoid trên validation.

[2] L. Prokhorenkova *et al.*, "CatBoost: Unbiased boosting with categorical features," in *Proc. NeurIPS*, 2018.

Cảnh báo theo ngân sách và cách đọc chỉ số

Ngân sách: mỗi sprint có n issue nhận tối đa $\lceil 0{,}2\,n \rceil$ cảnh báo, dành cho các issue có điểm rủi ro cao nhất. So sánh mô hình bằng paired bootstrap 2.000 lần (theo sprint / theo dự án).

Chỉ số	Ý nghĩa	Tốt khi
Recall@ngân sách	% issue thực sự trễ nằm trong danh sách cảnh báo	cao
Precision	% cảnh báo đúng	cao
Cảnh báo sai/sprint	số cảnh báo rơi vào issue cuối cùng vẫn xong	thấp
Lead time	số ngày từ lúc cảnh báo đến hết sprint	dài
AP	chất lượng xếp hạng trên mọi ngưỡng; ngẫu nhiên $\approx$ tỷ lệ lớp	gần 1
Brier	sai số bình phương của xác suất; đoán hằng $\approx 0{,}25$	thấp
Intercept / slope	xác suất có khớp tần suất thực tế không	0 / 1
Chênh lệch, CI 95%	recall động trừ recall tĩnh (điểm %); CI không chứa 0 $\Rightarrow$ có ý nghĩa	CI > 0

Kết quả chính: giả thuyết tại mốc 50%

Thiết kế	Tĩnh	Động	Chênh lệch	CI 95%	Đơn vị
Temporal	44,46%	53,36%	+8,90	[6,38; 11,70]	336 sprint
Cross-project	43,56%	53,52%	+9,96	[7,53; 12,82]	14 dự án

- Đọc: với khoảng 20% cảnh báo mỗi sprint, mô hình động bắt được trung bình 53% số issue sẽ trễ, mô hình tĩnh bắt được 44%. CI không chứa 0, nên giả thuyết chính được ủng hộ.
- Cùng 850 cảnh báo (temporal): phát hiện 682 so với 605 issue (trên tổng 1.883); precision gộp 80,24% so với 71,18%; cảnh báo sai 168 so với 245 (0,42 so với 0,62 mỗi sprint).

Chính xác hơn nhưng muộn hơn

Mốc	0%	25%	50%	75%
Recall động	45,12%	50,22%	53,36%	54,55%
Chênh lệch (điểm %)	+0,66*	+5,76	+8,90	+10,09
Lead time TB	∼12,6 ngày	∼9,5 ngày	∼6,3 ngày	∼3,1 ngày

* CI 95% [−0,89; 2,04] chứa 0. Recall tĩnh = 44,46% ở mọi mốc.

- Ở mốc 0% chưa có lịch sử nên hai mô hình ngang nhau. Đây là kết quả kỳ vọng và cho thấy không có rò rỉ thông tin.
- Mốc muộn hơn cho chênh lệch lớn hơn nhưng ít thời gian xử lý hơn. Đề tài không chọn một mốc "tối ưu" duy nhất.

Kiểm tra độ vững: phải đọc kỹ

Chênh lệch động – tĩnh tại 50% (điểm %)	Temporal	Cross-project
Chính: $\lceil 0{,}2n \rceil$	+8,90 [6,38; 11,70]	+9,96 [7,53; 12,82]
Làm tròn xuống $\lfloor 0{,}2n \rfloor$	+3,82 [2,20; 5,67]	+6,09 [4,34; 8,09]
Chỉ issue còn mở	+2,59 [0,68; 4,69]	+2,03 [0,73; 3,58]
Chỉ tính Closed là hoàn thành	+1,87 [0,83; 3,04]	+1,95 [0,32; 3,81]

Ba lưu ý

1. Phần lớn lợi thế đến từ việc nhận ra issue đã Done: `dynamic_is_done` chiếm 27,41% / 56,44% importance.
2. Ngân sách thực tế không phải 20%: 207/397 sprint có dưới 5 issue, nên tỷ lệ cảnh báo thực tế là 41,54% (macro) / 25,81% (micro).
3. Mọi chênh lệch vẫn dương và có ý nghĩa, nhưng nhỏ hơn nhiều so với con số chính.

Chất lượng xác suất (mốc 50%)

		AP TB dự án	Brier thô	Brier HC	Intercept	Slope
Temporal	tĩnh	0,6571	0,2188	0,1894	0,49 → 0,03	0,66 → 0,88
	động	0,8128	0,1279	0,1137	0,57 → 0,09	0,87 → 1,03
Cross-project	tĩnh	0,6359	0,2257	0,2241	0,17 → −0,09	0,67 → 0,74
	động	0,8035	0,1374	0,1381	0,20 → −0,004	0,89 → 0,92

HC: sau hiệu chuẩn. Lý tưởng: intercept 0, slope 1. Đoán ngẫu nhiên: AP ≈ 0,47–0,57; Brier ≈ 0,25.

- Mô hình động xếp hạng tốt hơn rõ rệt (AP ∼0,65 → ∼0,81).
- Cross-project: Brier không cải thiện, nên cần hiệu chuẩn lại trên dữ liệu Agentick.

So với quy tắc đơn giản và giữa các dự án (khám phá)

Chênh lệch tại 50% (điểm %)	Temporal	Cross-project
Động – quy tắc nghiệp vụ	+2,13 [−0,33; 4,60]	+3,83 [2,10; 5,73]
Động – không cohort	−0,87 [−2,26; 0,29]	+0,72 [0,05; 1,42]
Tuần tự: động – tĩnh	+1,30 [−0,46; 3,21]	+1,88 [0,60; 3,14]

- Trên sprint tương lai, chưa chứng minh ML hơn quy tắc (recall 51,23% so với 53,36%; CI chứa 0).
- Cảnh báo tuần tự: recall 51,56%, precision 77,67%, lead time ∼8,3 ngày, so với ∼6,3 ngày khi chỉ cảnh báo một lần ở 50%.
- Giữa các dự án: chênh lệch động – tĩnh dương ở cả 14 dự án nhưng dao động mạnh (temporal +2,6 đến +35 điểm), nên không suy ra được mức cải thiện cho một nhóm cụ thể.

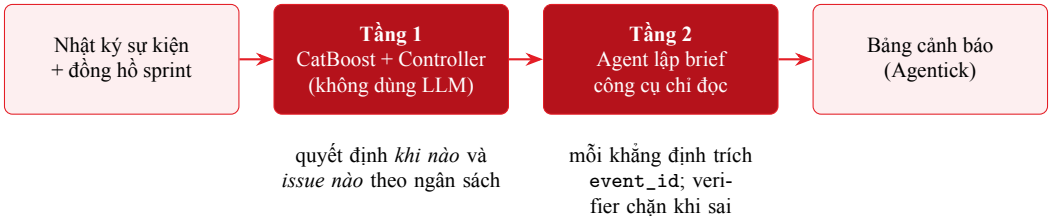
Phân bổ cảnh báo theo thời gian (khám phá)

Câu hỏi: giữ tổng K cảnh báo, chỉ xét issue còn mở. Phát sớm một phần (*quota*) có tốt hơn phát hết ở mốc 50% (*midpoint*) không?

$K = 2$, temporal	**Quota**	**Midpoint**
Recall phát hiện sớm	58,77%	59,20%
Precision	77,31%	79,70%
Lead time	8,18 ngày	6,29 ngày

- Chênh lệch recall (quota – midpoint): $-0{,}43$ $[-1{,}36;\ 0{,}55]$ (temporal); $-1{,}08$ $[-1{,}88;\ -0{,}35]$ (cross-project).
- Kết luận: sớm hơn $\sim$1,9 ngày nhưng không tăng recall. $K = 2$ là giá trị được khảo sát, không phải giá trị tối ưu đã chứng minh.

Kiến trúc agent: hai tầng



- Công cụ: `get_issue_evidence`, `get_sprint_summary`; chỉ thấy sự kiện *as-of* và thuộc đúng dự án.
- Kiểm tra: `EvidenceVerifier` chặn brief vi phạm trước khi hiển thị.
- LLM (`gemini-3.5-flash-lite`, temperature 0,1) tự gọi công cụ, tối đa 3 bước; không sinh xác suất, không sửa sprint.

Agent làm được gì

Khả năng	Cách thực hiện
Lấy bằng chứng của issue	`get_issue_evidence(issue_id)`: trạng thái, số ngày không hoạt động, ước lượng, điểm rủi ro (CatBoost), các sự kiện đến thời điểm dự báo
Lấy tổng quan sprint	`get_sprint_summary()`: dự án, sprint, số issue, danh sách issue
Đề xuất cảnh báo / bỏ qua	trả về `alert` hoặc `abstain` kèm lý do
Viết brief có cấu trúc	loại rủi ro, giá trị đo, `event_id` làm căn cứ, việc nên kiểm tra, điều chưa biết

Ràng buộc cài trong mã: chỉ đọc; lọc sự kiện sau thời điểm dự báo; chặn issue của dự án khác; nội dung issue gắn nhãn không tin cậy; verifier chặn `event_id` bịa, số liệu sai, khẳng định nhân quả.

Ví dụ: agent gọi công cụ lấy bằng chứng

Issue 177929, dự án CONFSERVER, sprint 2393, mốc 50% (13/01/2014). Trace thật.

Agent gọi: `get_issue_evidence(issue_id="177929")`

Công cụ trả về (rút gọn):

```
status            : open
inactive_days     : 7.0
estimate          : 5.0
risk_score        : 0.863    <- do CatBoost tính
untrusted_content : true
events:
  EVT-CONFSERVER-177929-created        04/01/2014  CREATED
  EVT-CONFSERVER-177929-sprint-start   06/01/2014  COMMITTED
  EVT-CONFSERVER-177929-status-update  06/01/2014  status = open
```

Ví dụ: brief agent trả về

- Quyết định: `alert`
- Khẳng định (`status_stagnation`, 7,0 ngày): “Issue 177929 được tạo 04/01/2014, đưa vào sprint 06/01/2014 với trạng thái open, và giữ nguyên open trong 7,0 ngày đến thời điểm dự báo.”
- Căn cứ: 3 `event_id` ở slide trước.
- Nên kiểm tra: người phụ trách có bị chặn / chưa rõ yêu cầu? Có tiến triển nhưng chưa cập nhật trạng thái?
- Chưa biết: có commit hay thay đổi mã ngoài hệ thống issue không.

Verifier: `event_id` có thật, 7,0 ngày khớp dữ liệu $\Rightarrow$ brief được chấp nhận. Thực tế issue này không hoàn thành trong sprint.

Giới hạn

1. Chưa triển khai thực nghiệm: agent chưa tích hợp vào Agentick, mọi kết quả đều từ benchmark TAWOS.
2. Trên issue còn mở, cải thiện chỉ ∼2–2,6 điểm.
3. Ngân sách “20%” thực tế cao hơn 20%.
4. Chưa chứng minh ML hơn quy tắc đơn giản (temporal).
5. Xác suất không chuyển giao giữa dự án.
6. Phân tích phân bổ cảnh báo và một số so sánh là post-hoc.
7. Mô phỏng không chứng minh cảnh báo làm giảm trễ.

Tiến độ hiện tại

Đã hoàn thành

- Protocol, nhãn, cohort; giả thuyết chính đăng ký trước
- Pipeline TAWOS → PostgreSQL, snapshot as-of 4 mốc
- 6 mô hình, đánh giá temporal/cross-project, sensitivity
- Bản thảo bài báo (LaTeX)
- Phân tích phân bổ cảnh báo theo thời gian
- Mô-đun agent (công cụ chỉ đọc, brief, verifier)

Đang chờ / chưa làm

- Tích hợp agent vào Agentick (bước tiếp theo)
- Registry mô hình, endpoint dự báo
- Kiểm tra agent trên dữ liệu Agentick
- Ledger/outbox, bảng cảnh báo, dry-run

Agentick là dự án riêng bên ngoài, đã có mã nguồn, dùng để thu dữ liệu và chạy thực nghiệm. Mọi kết quả hôm nay đều từ benchmark TAWOS.

Roadmap và kế hoạch (tính từ T0 = hôm nay)

Giai đoạn	Thời gian	Công việc	Tiêu chí xong
1. Tích hợp Agentick	T0 → +2 tuần	Nối dữ liệu vào pipeline as-of; endpoint dự báo; bảng cảnh báo, ledger, dry-run	Agentick hiển thị issue rủi ro + brief; log có phiên bản
2. Hoàn thiện kiểm tra agent	song song bước 1	Chạy agent trên issue được chọn từ Agentick; kiểm tra trích dẫn, số liệu	Agent chạy trong luồng cảnh báo, brief lưu kèm trace
3. Thực nghiệm	+2 → +5 tuần	Shadow mode, hiệu chuẩn lại, so với quy tắc	Recall, precision, lead time trên dữ liệu thật
4. Báo cáo cuối	2 tuần cuối	Tổng hợp, hoàn thiện bài báo và ứng dụng	Báo cáo, mã, dữ liệu tái lập

Shadow mode: dự báo và brief được ghi log nhưng chưa gửi cho người dùng. Chỉ sang bước 3 khi dữ liệu Agentick tái dựng được phạm vi cam kết và trạng thái hoàn thành, theo cùng tiêu chí đã dùng với TAWOS.

Tóm tắt

- Lịch sử thực thi cải thiện khả năng phát hiện issue sắp trễ (+8,90 / +9,96 điểm tại 50%), giữ được trên dự án chưa thấy.
- Phần lớn lợi thế đến từ việc nhận biết issue đã xong. Trên issue còn mở, mức cải thiện nhỏ nhưng vẫn có ý nghĩa.
- Mô-đun agent đã xây xong: tự lấy bằng chứng tại thời điểm dự báo, đề xuất cảnh báo và viết brief trích dẫn sự kiện có thật.
- Bước tiếp theo: tích hợp vào Agentick, kiểm tra agent, thực nghiệm shadow mode trên dữ liệu thật.

Tài liệu tham khảo

[1] F. Tu, J. Zhu, Q. Zheng, and M. Zhou, “Be careful of when: An empirical study on time-related misuse of issue tracking data,” in *Proc. ESEC/FSE*, 2018.

[2] L. Prokhorenkova *et al.*, “CatBoost: Unbiased boosting with categorical features,” in *Proc. NeurIPS*, 2018.

[3] E. Debenedetti *et al.*, “AgentDojo: A dynamic environment to evaluate prompt injection attacks and defenses for LLM agents,” arXiv:2406.13352, 2024.

[4] V. Tawosi, A. Al-Subaihin, R. Moussa, and F. Sarro, “A versatile dataset of agile open source software projects,” in *Proc. MSR*, 2022, pp. 707–711.

[5] I. Verenich *et al.*, “Survey and cross-benchmark comparison of remaining time prediction methods in business process monitoring,” *ACM TIST*, 2019.

[6] M. Kubrak *et al.*, “Prescriptive process monitoring: Quo vadis?,” *PeerJ Comput. Sci.*, 2022.